

Studie: Flow beim Laufen

Simon Bogutzky

April 2015

Abkürzungsverzeichnis

AFP	Anforderungs-Fähigkeits-Passung	2
EKG	Elektrokardiogramm	2
FFT	Fast Fourier Transformation	5
FKS	Flow-Kurzskala	1
GPS	Global Positioning System	2
HF	High Frequency	6
HRV	Herzratenvariabilität	4
LF	Low Frequency	6
VHF	Very High Frequency	6
WT	Wavelet Transformation	6

Ziel

Die Studie diente dazu statistische Beziehungen zwischen:

- Flow und der Aktivität des autonomen Nervensystems
- Flow und dem Bewegungsfluss

beim Laufen herzustellen. Des Weiteren suchte ich in den Daten nach markanten Mustern, die den Eintritt in den Flow, Flow selbst und den Austritt aus dem Flow markieren.

Methode

Flow-Diagnostik

Flow-Kurzskala

Zur subjektiven Erfassung des Flow-Erlebens kam die Flow-Kurzskala (**FKS**) von [Rheinberg et al. \(2003\)](#) zum Einsatz. Die **FKS** besteht aus insgesamt 16 Items. Die ersten zehn Items bilden anhand einer 7-Punkte-Likert-Skala (“trifft nicht zu” = 1 bis “trifft zu” = 7) Komponenten des Flow-Erlebens ab und [Rheinberg et al. \(2003\)](#) fassen sie als Generalfaktor zusammen. Zur Differenzierung des Flow-Konstrukts ist der Generalfaktor der **FKS** in zwei Faktoren (Subdimensionen) unterteilt. Faktor I umfasst sechs Items, die Aussagen zum “Glatten automatisierten Verlauf” einer Tätigkeit beschreiben. Faktor II beinhaltet vier Items, die mit “Absorbiertheit” in

Zusammenhang stehen. Der Reliabilitätskoeffizient der zehn Items im Generalfaktor (Cronbachs Alpha) liegt nach Angaben von Rheinberg et al. (2003, S. 9) im Bereich um $\alpha = 0.90$. Da nicht damit zu rechnen ist, dass in Anforderungssituationen ausschließlich Flow entsteht, sondern Anforderungssituationen auch Angst und Besorgnis auslösen können, erweiterten Rheinberg et al. (2003) die FKS durch eine “Besorgniskomponente”. Diese besteht aus drei Items (Nr. 11 bis 13, Cronbachs $\alpha = 0.80$ bis $\alpha = 0.90$). Am Ende der FKS nehmen die Probanden drei Einschätzungen zur Anforderungs-Fähigkeits-Passung (AFP) (auf einer 9-Punkte-Skala) vor. Das Item 14 fokussiert sich auf einen Vergleich der Schwierigkeit der jetzigen Tätigkeit mit allen anderen Tätigkeiten (leicht vs. schwer) und das Item 15 auf die eigene Leistungsfähigkeit (niedrig vs. hoch). Das Item 16 fragt direkt, auf die aktuelle Tätigkeit bezogen, nach der subjektiv wahrgenommenen AFP (zu gering vs. zu hoch).

Untersuchungsdesign

Ein männlicher Freizeitläufer (29) nahm am Experiment teil. Er lief in sechs aufeinanderfolgenden Wochen an einem Tag 60 Minuten jeweils die gleiche Strecke und zur gleichen Tageszeit.

Vor jedem Lauf rüstete ich ihn mit einem geladenen Smartphone, einem passenden Smartphone-Armband, zwei geladenen Bewegungssensoren, einem geladenen Elektrokardiogramm (EKG)-Sensoren und vier Elektroden aus. Die Anordnung des Equipments ist Abbildung 1 zu entnehmen.

Während jedes Laufes zeichnete eine eigens entwickelte App EKG und Bewegungsdaten mit Hilfe der tragbaren Sensoren des Unternehmens Shimmer Research (Shimmer 2r) auf. Die App läuft auf dem Android OS ab Version 4.4 und kommuniziert mit den Sensoren über Bluetooth. Die Bewegungssensoren besitzen einen Beschleunigungsmesser und ein Kreiselinstrument, die beide auf jeweils drei Achsen messen. Für das Experiment nutzte ich das Smartphone Samsung Galaxy Nexus, welches auch über einen Beschleunigungsmesser und ein Kreiselinstrument verfügt. Alle Bewegungssensoren arbeiten mit einer Datenrate von 100 Hz. Der EKG-Sensor von Shimmer Research arbeitet mit vier Ableitungen. Im Experiment nutzte ich Knopfelektroden und eine Datenrate von 256 Hz. Alle 15 Minuten während jedes Laufes forderte die App mit einem Signal den Läufer auf, eine FKS auszufüllen. Vor jedem Lauf führte der Läufer eine 15-minütige Baseline Messung durch.

Nach jedem Lauf übertrug ich die gesammelten Daten für die software-technische Analyse auf meinen Arbeitsrechner. Die Daten bestehen für jeden Lauf aus der Bewertung der fünf FKS, EKG-Daten, Global Positioning System (GPS)-Positionen, Beschleunigungen und Winkelgeschwindigkeiten von den Körperpositionen Bein, Arm und Handgelenk.

Datenverarbeitung

Flow-Kurzskala Aus der Bewertung der FKS berechnete ich die Faktoren der FKS. Tabelle 1 zeigt die Ergebnisse der FKS des Laufes vom Donnerstag, den 31. Oktober 2013. In dieser Sitzung steigt z. B. die AFP kontinuierlich und beim Laufen bewertet der Läufer seine Absorbiertheit gleichbleibend im mittleren Bereich (siehe Abbildung 2).




Abbildung 1: Anordnung des Equipments

Tabelle 1: Ergebnisse vom Donnerstag, den 31. Oktober 2013

	Baseline	Nach 15 Min.	Nach 30 Min.	Nach 45 Min.	Nach 60 Min.
Generalfaktor	5.00	1.05	5.10	0.57	4.90
glatter Verlauf	5.67	0.52	5.33	0.52	5.17
Absorbiertheit	4.00	0.82	4.75	0.50	4.50
Besorgnis	2.00	0.00	2.00	0.00	2.00
AFP	3.33	2.31	4.00	1.73	4.33

Zur Bewertung des subjektiven Flow-Zustands verwende ich die zweite Subdimension der **FKS**. Denn die Absorbiertheit tritt laut [Peifer et al. \(2014\)](#) nur ein, wenn Anforderungen und Fähigkeiten sich in Balance befinden — somit ist sie ausschließlich im *Flow-Kanal* anzutreffen. Deshalb die Absorbiertheit ein repräsentativer Indikator für Flow als der Generalfaktor, der sich aus den zwei Subdimension zusammensetzt. Den Beleg hierfür geben [Rheinberg & Vollmeyer \(2003, S. 69\)](#). Sie stellten fest, dass Unterforderung keinen Einfluss auf den glatten Verlauf hat, jedoch die Absorbiertheit negativ beeinflusst. Auch im Vergleich von Baseline und Laufmessung (siehe Abbildung 2) ist dieser Sachverhalt auszumachen.




Abbildung 2: Absorbiertheit, AFP und glatter Verlauf

HRV-Analyse Von den **EKG**-Daten entfernte ich die Zeiten für die Bewertung der **FKS** und erhielt jeweils 15-Minuten Abschnitte (siehe Abbildung 3 von A zu B). Zur effizienteren Verarbeitung in KubiosHRV teilte ich die 15-Minuten Abschnitte in jeweils drei fünf Minuten Abschnitte (siehe Abbildung 3 C). Zur RR-Interval Berechnung las ich die 90 fünf Minuten Abschnitte in KubiosHRV (Version 2.1) ein. KubiosHRV R-Spitzen-Erkennung identifiziert grötenteils die Herzschläge automatisch, trotzdem ist eine manuelle Nachbearbeitung notwendig. Nicht erkannte Herzschläge fügte ich hinzu und zuviel erkannte Herzschläge entfernte ich. **EKG**-Daten mit mehr als 2% an Artefakten habe ich aus der Datensammlung entfernt. Zur Herzratenvariabilität (**HRV**)-Analyse nutze ich die letzten fünf Minuten jedes 15-Minuten Abschnittes. Das hatte folgende

Gründe:

- Die ersten fünf Minuten sind beeinflusst von der Ruhephase vor dem Lauf und nach jeder Befragung (siehe Abbildung 3 C am Anfang)
- Die letzten fünf Minuten liegen direkt vor der Befragung (siehe Abbildung 3 C am Ende)
- Für die letzten fünf Minuten musste ich keinen Datensatz aufgrund von Artefakten aus der Datensammlung entfernen




Abbildung 3: EKG-Signalverarbeitung

Nach der Berechnung der RR-Intervalle analysierte ich die **HRV** in R mit Hilfe des Package RHRV (Rodríguez-Liñares et al. 2010). Im ersten Schritt filterte ich die RR-Intervalle mit der in RHRV integrierten Filterfunktion. Sie implementiert einen Algorithmus, der einen adaptiven Grenzwert nutzt, um RR-Intervalle abzulehnen oder zu akzeptieren. Der Algorithmus vergleicht den gegenwärtigen RR-Intervall mit dem vorherigen RR-Intervall, dem nachfolgenden RR-Intervall und einem Mittel der letzten 50 RR-Intervalle. Der Unterschied zwischen den drei Vergleichen darf für eine Akzeptanz nicht mehr als 13% betragen. Zusätzlich muss der gegenwärtige RR-Intervall zwischen einem Maximalwert und Minimalwert von drei Standardabweichungen vom Mittel liegen, damit die Funktion ihn nicht herausgefiltert (wie bei de Manzano et al. (2010)). Im nächsten Schritt interpolierte ich linear (4 Hz) die RR-Intervalle, damit ein gleicher zeitlicher Abstand zwischen den Datensätzen gewährleistet ist.

Ein Grundproblem der **HRV**-Analyse unter sportlicher Belastung ist die Nichtstationarität des Herzfrequenzsignals (RR-Intervalle). Aus diesem Grund empfehlen Sarmiento et al. (2013, S.

113) traditionelle Methoden der Spektralanalyse wie die Fast Fourier Transformation (**FFT**) nicht zu verwenden. Auch Hoos (2010, S. 61) schreibt von Autoren, die argumentieren, dass für hohe Intensitäten Ergebnisse der traditionellen Spektralanalyse der **HRV** im Allgemeinen und insbesondere der absoluten Einheiten zur Beschreibung der autonomen Funktion unter sportlicher Belastung kaum geeignet sind. Sie führen dies einerseits auf methodische Probleme wie der belastungsbedingten Nichtstationarität und andererseits auf ihre mangelnde Vergleichbarkeit mit Ergebnissen unter schwachen Intensitäten zurück. Vgl. Hoos (2010, S. 61) lässt sich die gewohnte belastungsinduzierte Verschiebung von der vagalen zur sympathikotonen Dominanz oftmals nicht feststellen.

Daraus folgt laut Hoos (2010, S. 61f.) die Forderung deutlich adäquaterer Methoden einzusetzen. Zu diesen Methoden gehören alternative Spektralanalysemethoden (z. B. Coarse Graining Spektralanalyse (CGSA), Kurzzeitfourier-Analyse (STFT) oder kontinuierliche Wavelet Transformation (CWT)) oder nicht-lineare Verfahren (insbesondere Detrended Fluctuation Analysis (DFA), Sample Entropie (SampEn)). Bei der Nutzung von alternativen Spektralanalysemethoden unter sportlicher Belastung fordern die von Hoos (2010, S. 62) zitierten Wissenschaftler die Verwendung von einer belastungsadäquaten Erweiterung des HF-Spektralbands mindestens bis zur maximalen Atemfrequenz (~ 1 Hz). Des Weiteren fordern sie eine Abkehr von der bisherigen Interpretation der Spektralbänder, da sich im High Frequency (**HF**)-Band bei sportlicher Belastung vor allem mechanisch bedingte Resonanz- und Kopplungsphänomene mit der Atmung und der motorischen Aktivität zu manifestieren scheinen.

Aufgrund der vorgestellten Forderungen verwende ich eine Wavelet Transformation (**WT**) zur Spektralanalyse. Die **WT** ist ein leistungsfähiges Werkzeug zur Analyse von nichtstationären Signalen wie der Zeitreihe der RR-Intervalle. Die Analyse basiert auf einem Mutter-Wavelet. Das Mutter-Wavelet ist eine lokalisierte, oszillierende, reguläre Funktion $\psi(t)$. Wavelet-Funktionen sind anders als die Sinusfunktionen, auf der die **FFT** basiert, im Raum lokalisiert. Dadurch erhält die **WT** die zeitliche und spektrale Dimension. Für die Analyse nichtstationärer Signale ist damit vgl. Rodríguez-Liñares et al. (2010, S. 207) die **WT** der **FFT** vorzuziehen.

Die Verwendung der **WT** ermöglicht die detaillierte Bewertung der Entwicklung der Herzreaktion in der Zeit, in der sich der Organismus auf die Intensität des Laufens, aber vermutlich auch auf die Zustandsveränderung im Flow einrichtet. Die Veränderungen der **HRV**-Signalenergie (Gesamt, Low Frequency (**LF**) und **HF**-Very High Frequency (**VHF**)) versuche ich als Merkmal für die unterbrechungsfreie Flow-Diagnostik nutzen. Dabei verwende ich die folgenden Signalbänder: **LF** 0.04 - 0.15 Hz; **HF-VHF** 0.15 - 1 Hz

Die **WT** führe ich in R mit der Hilfe des RHRV Packages durch. In RHRV implementierten Rodríguez-Liñares et al. (2010) eine Maximal Overlap Discrete Wavelet Packet Transform (MODWPT). Zur Analyse stehen mehrere Wavelet-Funktion mit unterschiedlichen Längen zur Verfügung. Allgemein besitzen kürzere Wavelet-Funktionen eine bessere zeitliche Auflösung, aber eine schlechtere Frequenzauflösung. Auf der anderen Seite, besitzen längere Wellen in der Regel schlechtere zeitliche Auflösung, aber bieten eine bessere Frequenzauflösung. Bessere zeitliche Auflösung ermöglicht es, kürzere Zeitabständen zu studieren. Ich verwende deshalb ein asymmetrische Daubechies Wavelet der Länge 8 (la8), das laut Rodríguez-Liñares et al. (2010)

einen guten Kompromiss zwischen Frequenz- und Zeitauflösung bietet.

Zur Berechnung der üblichen Spektralleistung der unterschiedlichen Bänder in ms^2 berechne ich das Mittel der Wavelet Koeffizienten. Die daraus resultierenden HRV-Merkmale des Laufes vom Donnerstag, den 31. Oktober 2013 bildet Tabelle 2 ab.

Tabelle 2: Ergebnisse vom Donnerstag, den 31. Oktober 2013

	Baseline	Nach 15 Min.	Nach 30 Min.	Nach 45 Min.	Nach 60 Min.
Mittlere Herzrate (BPM)	55.26	169.14	174.56	179.13	179.87
LF (ms^2)	2416.85	0.97	1.66	0.75	0.64
HF-VHF (ms^2)	661.61	3.04	7.16	3.09	5.51
Gesamt (ms^2)	13124.58	16.67	22.22	26.90	19.11
LF (%)	18.41	5.84	7.49	2.79	3.36
HF (%)	5.04	18.24	32.23	11.50	28.84
LF (n. u.)	78.51	24.25	18.86	19.54	10.43
HF-VHF (n. u.)	21.49	75.75	81.14	80.46	89.57
LF/HF-VHF	3.65	0.32	0.23	0.24	0.12

Literatur

de Manzano, O., Theorell, T., Harmat, L. & Ullén, F. (2010), ‘The psychophysiology of flow during piano playing.’, *Emotion (Washington, D.C.)* **10**(3), 301–311.

URL: <http://www.ncbi.nlm.nih.gov/pubmed/20515220>

Hoos, O. (2010), Herzfrequenzvariabilität (HRV) bei sportlicher Belastung, in K. Hottenrott, O. Hoos & D. Esperer, eds, ‘Herzfrequenzvariabilität: Gesundheitsförderung Trainingsteuerung Biofeedback’, pp. 55–71.

Peifer, C., Schulz, A., Schächinger, H., Baumann, N. & Antoni, C. H. (2014), ‘The relation of flow-experience and physiological arousal under stress — Can u shape it?’, *Journal of Experimental Social Psychology* **53**, 62–69.

URL: <http://linkinghub.elsevier.com/retrieve/pii/S0022103114000109>

Rheinberg, F. & Vollmeyer, R. (2003), ‘Flow-Erleben in einem Computerspiel unter experimentell variierten Bedingungen’, *Zeitschrift für Psychologie*, **4** (Flow experience in a computer game under experimentally controlled conditions), 161–170.

Rheinberg, F., Vollmeyer, R. & Engeser, S. (2003), ‘Die Erfassung des Flow-Erlebens’, *Diagnostik von Motivation und Selbstkonzept* pp. 261–279.

URL: <http://opus.kobv.de/ubp/volltexte/2006/634/>

Rodríguez-Liñares, L., Méndez, a. J., Lado, M. J., Olivieri, D. N., Vila, X. a. & Gómez-Conde, I. (2010), ‘An open source tool for heart rate variability spectral analysis.’, *Computer methods and programs in biomedicine* **In Press**, 1–12.

URL: <http://www.ncbi.nlm.nih.gov/pubmed/20674067>

Sarmiento, S., García-Manso, J. M., Martín-González, J. M., Vaamonde, D., Calderón, J. &

da Silva-Grigoletto, M. E. (2013), ‘Heart rate variability during high-intensity exercise’, *Journal of Systems Science and Complexity* **26**(1), 104–116.